

QUANTITATIVE RESEARCH

# A 股量化策略 研究项目完整报告

九轮迭代实证 · 从零基础到真实可信 alpha 策略

+4.40%

净年化超额

0.445

信息比率

5.4 年

测试期

Microsoft Qlib · LightGBM · 自建 baostock 数据管线

CSI500 历史并集 1623 只 · 含真实交易成本 0.3%

2026 年 5 月

v1.0 Final

# 目录 / Contents

|                          |    |
|--------------------------|----|
| 执行摘要                     | 03 |
| 1 项目背景与方法论               | 05 |
| 2 数据管线建设                 | 07 |
| 3 九轮迭代纪要                 | 09 |
| 第 1 轮 · 经典基线 (CSI300 短期) |    |
| 第 2 轮 · 长测试集打回原形         |    |
| 第 3 轮 · 降换手救活策略          |    |
| 第 4 轮 · 估值因子 (信号好回测平)    |    |
| 第 5 轮 · 超参优化失败           |    |
| 第 6 轮 · 换战场 CSI500 (突破)  |    |
| 第 7 轮 · CSI500 含偏巅峰      |    |
| 第 8 轮 · 去幸存者偏差 (真相)      |    |
| 第 8.5 轮 · 工具箱重新校准        |    |
| 第 9 轮 · 模型集成+行业中性化失败     |    |
| 4 可视化呈现 (10 张关键图表)       | 22 |
| 5 最终最优配置规格               | 30 |
| 6 核心方法论收获                | 32 |
| 7 未来路线图                  | 34 |
| 附录 A 项目目录结构              |    |
| 附录 B 工程踩坑记录              |    |
| 附录 C 术语词典                |    |

## 执行摘要

本项目从零 Python 基础起步，使用 Microsoft Qlib 框架对 A 股市场进行系统化量化策略研究，历经 9 轮迭代 + 1.5 轮方法论校验，在严格防过拟合的前提下，最终确立了一个 **真实可信、无方法论隐患** 的多头选股策略：

### ★ 最终最优配置

CSI500 历史并集 + Alpha158 + LightGBM 默认超参 + TopkDropoutStrategy(topk=30, n\_drop=1)

5.4 年含真实历史成分变更回测、含双边 0.3% 交易成本

## 关键成果指标

**+4.40%**

净年化超额

**0.445**

信息比率

**0.566**

净夏普

**-12.6%**

超额最大回撤

## 项目核心价值

项目的真正成就不在于“高 IR”（0.45 仍低于实战可用线 1.0），而在于建立了严谨、可复现、零方法论隐患的研究流程。

所有“漂亮数字”都经过**去偏 / 长测试集 / 不碰测试集**的反复校验：

- 第 1 轮的 **+8.85%**（短测试集海市蜃楼）→ 第 2 轮长测试集打回 **-0.97%**
- 第 7 轮的 **+14.94%**（幸存者偏差版本）→ 第 8 轮去偏后打回 **+3.91%**
- 第 9 轮试图通过**集成 / 行业中性化突破** +4.40% → 全部失败，反而印证当前框架已到上限

剩下的 **+4.40% / IR 0.45** 是经过所有方法论审查后的**真金白银**。

### 熊市防御性突出

2022 年中证500 指数跌 **-20.4%**，本策略仅跌 **-5.6%**（净超额 **+14.8%**），显示出明确的“抗跌”特性。

## 方法论收获概览

- 长测试集是底线**，不是可选 — 5 个月测试集救了我们一次潜在实盘灾难
- 降换手是免费午餐** — 第 3 轮模型不变、净超额 **-0.97% → +2.81%**
- IC 涨 ≠ 回测涨** — 项目 5 次出现该现象（R4、R5、R8.5 重调、R9 集成、R9 中性化）
- 战场决定上限** — CSI500 vs CSI300 同模型 IR 翻倍多
- 简单胜过复杂** — 最终配置打败 200+ 轮 Optuna 调出的复杂方案
- 幸存者偏差实际虚高 11 pp**（远超经典估计 2-4 pp），中盘股尤甚

# 1 项目背景与方法论

## 1.1 研究目标

项目同时承担学习与实证双重目标：

- **学**：边做边学量化研究的完整方法论流水线 — 数据采集 → 因子工程 → 模型训练 → 策略构建 → 回测评估 → 迭代改进
- **做**：在 A 股市场，在严格防过拟合的前提下，找出净超额  $> 0$  且经得起任何审查的可信策略
- **守住的底线**：所有结论必须能通过方法论复审；不接受任何“看上去很美”的回测

## 1.2 防过拟合铁律（贯穿全项目）

从 CLAUDE.md 中定义、9 轮研究中严格执行的 5 条铁律：

| # | 规则      | 用例与说明                                                           |
|---|---------|-----------------------------------------------------------------|
| 1 | 长测试集    | 测试期至少 3 年、最好 5+ 年，需跨越牛熊市                                        |
| 2 | 严格不碰测试集 | 超参搜索 / 策略调参只能在 2018–2019 验证集上做；测试集 2020–10 ~ 2026–05 只在最终评估时跑一次 |
| 3 | 必含交易成本  | A 股双边 0.3%（佣金 + 印花税 + 滑点）写死在每个回测里                               |
| 4 | 历史成分股   | 股票池要用真实历史成分（每年都不同），不能只取“今天还在指数里的赢家”                             |
| 5 | 警惕完美回测  | 年化 $> 50\%$ 、IR $> 3$ 一定是有问题；要倒查                                |

这 5 条规则在项目中被**反复印证**——每一条都救过我们一次。比如第 1 轮 9 个月测试集给出  $+8.85\%$  IR 1.04，第 2 轮一旦延长到 5.4 年立刻打回  $-0.97\%$ 。如果没守住“长测试集”这条规则，我们会以为找到了“圣杯”。

## 1.3 研究范式

### 数据分层

**训练集**：2010–01 ~ 2017–12（8 年）  
**验证集**：2018–01 ~ 2019–12（2 年，调参用）  
**测试集**：2020–10 ~ 2026–05（5.4 年，**只看一次**）

### 迭代节奏

每轮：假设 → 实现 → 回测 → 分析 → 决策  
记录到 `results/runs/round*/summary.md`  
关键决策点用户拍板，不擅自切换方向

## 2 数据管线建设

### 2.1 数据集演进

项目使用 4 代数据集，前一代不够用就用 baostock 自建后一代：

| 数据集        | 内容                                         | 状态     |
|------------|--------------------------------------------|--------|
| cn_data    | qlib 官方, 2010–2020/09                      | 废弃（停更） |
| cn_data_v2 | 790 只 CSI300 历史并集, 2010–2026               | 自建第一代  |
| cn_data_v3 | v2 + CSI500 当前 500 + SH000905 指数（共 1056 只） | 含偏差版   |
| cn_data_v4 | v3 + CSI500 历史并集（共 1840 只）                 | 最终去偏版本 |

每只股票 11 个字段：\$open \$high \$low \$close \$volume \$vwap \$factor + 4 个估值指标 \$pettm \$pbmrq \$psttm \$pcfcttm。

### 2.2 采集过程踩坑

baostock 限流是核心挑战。经历了如下迭代：

| # | 策略                             | 结果                           |
|---|--------------------------------|------------------------------|
| 1 | 8 worker 并发                    | 387/790 失败（IP 级限流）           |
| 2 | 降到 4 worker + 失败重登             | 勉强 ok，仍有部分失败                 |
| 3 | 单线程兜底 + 1s 间隔                  | 0 失败但很慢                      |
| 4 | 加 socket.setdefaulttimeout(30) | 避免 baostock 半挂死无限阻塞          |
| 5 | 多分片 + 循环重试 + 轮间冷却              | 最终方案：791+784+120 = 1695 只无失败 |

### 2.3 关键工程脚本

- baostock\_collector.py — OHLCV 多进程采集（含历史成分股查询）
- valuation\_collector.py + fetch\_val\_loop.py — 估值采集 + 循环兜底
- build\_qlib\_data.py — CSV → qlib 二进制格式
- collect\_industries.py — 行业归属（第 9 轮中性化用）

### 3 九轮迭代纪要

#### 3.0 完整战绩纵览

| 轮次   | 配置                       | 净超额             | IR           | 备注      |
|------|--------------------------|-----------------|--------------|---------|
| R1   | CSI300 9 个月基线            | +8.85%★         | 1.04★        | 海市蜃楼    |
| R2   | CSI300 5.4 年长测           | -0.97%          | -0.12        | 现实一巴掌   |
| R3   | + 降换手 (n_drop=1)         | +2.81%          | 0.37         | 救活了     |
| R4   | + 估值因子                   | +2.53%          | 0.34         | 信号好回测平  |
| R5   | + Optuna 调超参             | +1.79%          | 0.24         | 过拟合验证集  |
| R6   | 换 CSI500 (含偏)            | +9.01%          | 0.87         | 突破! 但含偏 |
| R7   | CSI500 + 调优 (含偏)         | +14.94%★        | 1.50★        | 含偏巅峰    |
| R8   | CSI500 去偏 + 调优套用         | +3.91%          | 0.473        | 真相浮出    |
| R8.5 | CSI500 去偏 + 默认 + topk=30 | +4.40%          | 0.445        | ★ 最终最优  |
| R9   | 集成 + 行业中性化 (多个)          | -0.83% ~ +3.52% | -0.09 ~ 0.31 | 全部失败    |

★ = 含有方法论隐患 (短期 / 幸存者偏差), 不是真实数字



图 1 | 项目演进 - 累计净值对比

5 个关键配置 + 2 条基准的累计净值曲线。NAVY 粗线 = 最终最优配置 R8.5。红色 = 含偏 R7 (项目最高点但虚高), 可对比观察含偏 vs 去偏差距。

## ROUND 1 · CSI300 BASELINE

### 经典基线 LightGBM + Alpha158 (9 个月)

假设 → 用 158 个量价因子的工业基线在 A 股能跑出可观超额

实现：qlib 自带 Alpha158 + LightGBM + TopkDropoutStrategy(topk=50, n\_drop=5)，CSI300 上跑 2020-01 ~ 2020-09。

结果：净年化超额 **+8.85%**，信息比率 **1.04**。

#### ⚠ 埋雷时刻

测试集只有 9 个月，且恰逢 2020 上半年牛市。数字可信度低。"好看的数字不一定是真的"——这是项目的第一个教训。

## ROUND 2 · LONG TEST SET

### 5.4 年长测试集 — 现实一巴掌

假设 → R1 可能是短期幸运，需要长测试集检验

实现：自建 baostock 数据管线，拉 790 只 CSI300 历史并集（消除幸存者偏差），测试期扩到 5.4 年。配置完全不变。

结果：净超额 **-0.97%**，IR **-0.12**。

#### ★ 收获

R1 的 +8.85% 是 2020 牛市的海市蜃楼。延长测试期立即打回原形。多 5 个月的努力就避免了一次潜在的实盘灾难。

## ROUND 3 · LOWER TURNOVER

### 降换手 — 救活了策略

假设 → 毛超额 +6.74% 是活的，但年化成本 7.7% 把它全吃了

实现：只改一个参数 `n_drop` 从 5 → 1。其他全不变。

|        | R2 基线         | R3            |
|--------|---------------|---------------|
| 净年化超额  | <b>-0.97%</b> | <b>+2.81%</b> |
| 信息比率   | <b>-0.12</b>  | <b>0.368</b>  |
| 日均换手   | 20.4%         | <b>4.5%</b>   |
| 年化交易成本 | 7.7%          | <b>1.7%</b>   |

#### ★ 关键收获

**降换手是免费午餐。**模型预测能力没变，但少交易 = 少交手续费 = 直接提净超额。这是项目第一个"圆满"的可用配置，也是后续所有轮次的基础。

### 加估值因子 — 信号变好，回测打平

假设 → Alpha158 全是量价，加估值（PE/PB/PS/PCF）因子能正交补充

实现：自建估值数据管线，写 Alpha158Plus handler 加 10 个估值因子。

|       | Alpha158 (158) | Alpha158Plus (168) |
|-------|----------------|--------------------|
| IC    | 0.0289         | 0.0335 (+16%) ↗    |
| 净超额   | +2.81%         | +2.53% ↘           |
| 正收益年数 | 4/7            | 6/7 ↗              |

模型重要性 Top 12 里 BP 排第 8、EP 排第 12——估值因子是真正的正交 alpha。但 IC 提升没转化为 TopK=50 的净超额。

★ 收获

估值因子让策略更稳健（赚钱年数 4/7 → 6/7），但绝对超额没提。保留估值因子是为了风格分散，不是为了暴增收益。

第一次出现"IC 涨 / 回测打平"现象——后续会再三重演。

### Optuna 超参优化 — 同一个反直觉重演

假设 → 调超参能把 IC 增益榨成回测收益

实现：Optuna 120 轮搜索，目标 = 验证集 RankICIR，严格不碰测试集。

|     | 默认超参   | 调优超参     |
|-----|--------|----------|
| IC  | 0.034  | 0.036 ↗  |
| 净超额 | +2.53% | +1.79% ↘ |
| IR  | 0.34   | 0.24 ↘   |

IC 又涨、回测又跌。搜出的复杂模型（叶子 507、深度 12、L1 几乎归零）在验证集表现更好，但没泛化到测试集。

★ 深层启示

**瓶颈不在模型，在战场。**5 轮在 CSI300 上的所有努力（扩数据、降换手、加因子、调超参）都没突破 +2.5% 的花板。**CSI300 自身被机构套利得太充分。**

## 换战场到 CSI500 — 真正的突破

假设 → 小盘股定价效率低，应该能榨更多 alpha

实现：补采 500 只 CSI500 当前成分 + 中证500 指数。**配置完全不变**，只把 instruments 改为 csi500。

|       | CSI300 (R3) | CSI500 (R6) |
|-------|-------------|-------------|
| 净年化超额 | +2.81%      | +9.01% 🚀    |
| 信息比率  | 0.37        | 0.87        |
| 净夏普   | 0.29        | 0.76        |

### ★ 重大收获

完全相同的模型/因子/策略，**仅换股票池，IR 翻 2.4 倍**。前 5 轮"瓶颈不在模型"的判断被强力印证。  
△ 但用的是当前 500 成分，**有显著幸存者偏差**——结论方向性可信但绝对数字偏乐观。

## CSI500 上快速迭代 — 触到"较好"线

把 CSI300 上验证过的工具（策略扫描 + Optuna）搬到 CSI500

结果：

|          | 默认超参    | 调优超参      |
|----------|---------|-----------|
| n_drop=1 | IR 0.87 | IR 1.50 ★ |

Optuna 在 CSI500 上反而帮上忙了——跟 CSI300 上的"调参变差"完全相反。

### ★ 关键洞察

超参优化是否管用，**取决于战场本身的信号强度**：

- CSI300 信号薄 → 调参易过拟合 → 变差
- CSI500 信号厚 → 调参有真空间可榨 → 大幅变好

CSI500 去幸存者偏差 — 真相浮出

实现 → 拉 CSI500 64 个季度历史成分快照 → 历史并集 1623 只 → 补采 784 只新股

|       | R7 含偏版  | R8 去偏版 | 差值        |
|-------|---------|--------|-----------|
| 净年化超额 | +14.94% | +3.91% | -11.03 pp |
| 信息比率  | 1.555   | 0.473  | -1.08     |
| 净夏普   | 1.008   | 0.586  | -0.42     |

★ 深刻方法论收获

幸存者偏差实际虚高了 11 个百分点——远超经典估算的 2-4 pp。在中证500 这种中盘上，淘汰率高，偏差严重得多。

第 7 轮 IR 1.55 看着像项目巅峰，第 8 轮直接打回 0.47。如果当初拿 IR 1.55 去实盘，会非常痛。



图 4 | 幸存者偏差可视化

同模型、同策略、同超参，仅数据集从含偏 v3 变去偏 v4。红色填充区 = 幸存者偏差虚高部分（累计 70 pp）。

### 去偏数据上重新校准工具箱 — 方法论闭环

假设 → R8 用的是 v3 调出的超参套到 v4 用，v4 上可能有更优配置

实现：在 cn\_data\_v4（去偏）上重跑 6 组策略扫描 + Optuna 80 轮。

| 配置                         | 净超额           | IR           | 净夏普          |
|----------------------------|---------------|--------------|--------------|
| v3 调优超参 + n_drop=1 (R8)    | +3.91%        | 0.473        | 0.586        |
| <b>v4 默认超参 + topk=30 ★</b> | <b>+4.40%</b> | <b>0.445</b> | <b>0.566</b> |
| v4 调优超参 + n_drop=1         | +3.36%        | 0.420        | 0.571        |

★ 三个进一步发现

- T3 (topk=30) 在含偏 v3 和去偏 v4 上都赢——真鲁棒
- T2 (n\_drop=2)、T6 (hold=10) 只在 v3 上赢——含偏数据的伪影
- v4 上重调 Optuna 验证集 RankICIR 涨了，但测试集 IR 反而没赢过 v3 调出的——"IC 涨 ≠ 回测涨"**第 4 次**出现

### 尝试突破 R8.5 上限 — 三个失败实验

实验 A：Ridge 线性模型。实验 B：4 种集成方案（等权 / IC加权 / 70–30 / Voting）。实验 C：行业中性化。

| 方案                 | 净超额           | IR            | vs R8.5        |
|--------------------|---------------|---------------|----------------|
| <b>R8.5 单模 LGB</b> | <b>+4.40%</b> | <b>+0.445</b> | —              |
| 单模 Ridge           | +3.52%        | +0.313        | 略差             |
| 等权融合               | <b>+0.60%</b> | <b>+0.057</b> | <b>暴跌</b>      |
| IC 加权              | <b>+1.55%</b> | <b>+0.142</b> | <b>暴跌</b>      |
| Voting (都进 top 60) | <b>−0.83%</b> | <b>−0.094</b> | <b>倒亏</b>      |
| + 行业中性化            | <b>−0.40%</b> | <b>−0.044</b> | <b>−4.8 pp</b> |

★ 失败的价值

所有改进失败 → 强力确认 R8.5 已是 Alpha158 框架的真实上限。要突破必须换**信号源**（基本面、另类数据、高频微观结构），不是换模型也不是加风控。

有时确认天花板比突破天花板更重要。

## 4 可视化呈现

本节展示项目核心 10 张图表。所有数据均来自经严谨防过拟合校验后的最终回测结果。




图 2 | 逐年净超额对比

4 个关键配置在 7 个年份上的净超额。2022 熊市策略普遍跑赢基准（防御性突出）。




图 3 | 项目五个关键配置三大指标横评

金色描边 = 当前指标最优。净超额由 R7 含偏版领先（虚高），但 R8.5 为去偏后最稳健。

图 5 | 最终配置月度净超额热力图 (CSI500 去偏 R8.5)




图 5 | 最终配置月度净超额热力图

5.4 年 × 12 月，每个色块为当月净超额。绿涨红跌。2022 年策略相对基准防御性突出。

图 6 | 最终配置 60 日滚动 IR / 净夏普 — 时间 定性




图 6 | 滚动 60 日 IR / 净夏普

时间稳定性视角。滚动 IR 多数时间为正，且超过虚线『可用』线 1.0 的时段不算少。




图 7 | 水下回撤图

策略距离历史新高的距离。深色 = 策略净回撤（受市场 beta 影响大）；绿色 = 超额回撤（仅 -12.6%）。




图 8 | LightGBM 因子重要性 Top 20

RANK5、MIN60、MA5 等短期动量类因子主导——A 股短期（2 日）预测的 alpha 主要来自动量结构。




图 9 | IC 时间序列

上图：累计 IC 一路上升——信号长期稳定为正。下图：日 IC 柱状，正比例 55–60%。

图 10 | 各配置日收益相关性矩阵




图 10 | 各配置日收益相关性矩阵

策略与基准相关性 0.85–0.95（长只多头属性）。策略之间相关性极高，提示单类信号空间，多策略组合需引入根本不同的信号源。

## 5 最终最优配置规格

### ★ R8.5 FINAL CONFIGURATION

CSI500 (历史并集去偏) + Alpha158 + LightGBM 默认超参 + TopkDropoutStrategy(topk=30, n\_drop=1, hold=1)

#### 5.1 实测指标 (5.4 年含真实成分变更)

| 指标        | 数值               | 评级               |
|-----------|------------------|------------------|
| 测试期       | 5.4 年 (1357 交易日) | ✅ 长              |
| 净年化超额     | +4.40%           | ✅ 真正 alpha       |
| 信息比率      | 0.445            | △ 接近"可用"线但未达     |
| 净夏普       | 0.566            | 一般 (受市场 beta 拖累) |
| 超额最大回撤    | -12.60%          | ✅ 可控             |
| 策略最大回撤    | -29.61%          | △ 市场 beta 拖累     |
| 日均换手      | 6.8%             | ✅ 合理             |
| 年化交易成本    | ~2.5%            | ✅ 已计入            |
| 正收益年份     | 4 / 7            | ✅ 稳健             |
| 2022 熊市表现 | +14.8% 超额        | 🔥 防御性突出          |

#### 5.2 配置详细 (可复现)

```
# 数据集 provider_uri: ~/.qlib/qlib_data/cn_data_v4 universe: csi500 # 历史并集 1623 只 benchmark: SH000905 # 中证500 指数 # 因子 factor_set: Alpha158 # 158 个量价因子 # 模型 (qlib 默认基准超参) model: LGBModel loss: mse learning_rate: 0.0421 num_leaves: 210 max_depth: 8 lambda_l1: 205.7 lambda_l2: 581.0 colsample_bytree: 0.888 subsample: 0.879 # 数据分割 segments: train: [2010-01-04, 2017-12-31] valid: [2018-01-01, 2019-12-31] test: [2020-10-01, 2026-05-15] # 策略 strategy: TopkDropoutStrategy topk: 30 # 每日持仓 30 只 n_drop: 1 # 每日强制换 1 只 hold_thresh: 1 # 交易成本 (A 股双边 0.3%) exchange: open_cost: 0.001 close_cost: 0.002 # 含 0.1% 印花税 min_cost: 5 limit_threshold: 0.095
```

## 6 核心方法论收获

这 6 条收获是 9 轮研究的"投资价值最大"的部分。每一条都来自真实的"踩坑后顿悟"，比"得到正确数字"更值钱。

### 1. 长测试集是底线，不是可选

R1 9 个月给 +8.85% / IR 1.04；R2 同配置 5.4 年立刻打回 -0.97% / IR -0.12。多 5 个月的努力就避免了一次潜在的实盘灾难。任何短测试集 (<3 年) 的回测都要打狠折扣。

### 2. 降换手是免费午餐

R3 把 `n_drop` 5 → 1，模型/因子/超参全不变，净超额 -0.97% → +2.81%。70% 的提升来自策略层一行参数。交易成本是量化里的"暗杀手"——A 股双边 0.3% 看似不大，高换手年化能吃掉 7-8% 的纸面 alpha。

### 3. IC 涨 ≠ 回测涨 (项目 5 次出现)

R4 加估值 (IC +16% / 回测 -0.3pp)、R5 调超参 (IC +6% / 回测 -0.7pp)、R8.5 v4 重调 (验证 RankICIR +8% / 测试 IR -0.05)、R9 集成 (IC 持平 / 回测崩盘)、R9 行业中性化 (ICIR +17% / 回测崩盘)。同一反直觉现象 5 次重演。

**背后本质：**IC 衡量"全部 500 只股票排序对不对"，但 TopK=30 只关心最尖端 30 只。整体排序变好不等于尖子选得更好。优化目标和真实目标永远有缝。

### 4. 战场决定上限

CSI300 上 5 轮努力 → 上限 IR 0.37。CSI500 同样的工具 → IR 0.45 (去偏后真实数字)。最大边际产出来自换战场，不是打磨模型。CSI300 太被机构套利充分了。

### 5. 简单胜过复杂

最终最优配置 = qlib 默认超参 + `topk=30` 一个改动，打败了 200 轮 Optuna 搜索调出的复杂超参组合。每一轮"看起来更复杂的方案"都没能赢过"简单方案"。过度拟合是过度优化的另一个名字。

### 6. 幸存者偏差实际虚高 11 PP (远超经典估计)

经典文献估算小盘股幸存者偏差年化虚高 2-4 pp。我们的实测是 11 pp!

R7 含偏版 +14.94% → R8 去偏版 +3.91%。在中盘股 (中证500) 淘汰率高的环境下，偏差严重得多。任何"只用当前成分"的回测都要打狠折扣。

## 7 未来路线图

项目走到 R8.5 + R9, 已确认在 Alpha158 量价因子框架下到达天花板。要再上一台阶, 必须换信号源。按工作量 / 预期收益排序:

### ● 短期 (1-2 天工作量, 纯本地数据)

- 组合优化器: 替代 TopK 为带约束 (行业上限、波动率上限、个股权重) 的组合优化
- 分层 long-only: 分 5/10 层多空表现, 识别哪些股票区间最有 alpha
- 风险因子调控: 在 Barra 风格上做暴露归因, 去掉非主动风险

### ● 中期 (1-2 周工作量, 需新数据源)

- 加财务因子 (季度 ROE / 营收增速 / 毛利率等) —— 需**点位安全**处理 (财报披露日延迟)
- 加一致预期因子 (分析师评级 / 调研频次) —— 需 Wind / 同花顺等付费源
- 扩到 CSI1000 或全市场 —— baostock 无 CSI1000, 需 akshare 接
- 深度学习模型 (LSTM / Transformer / TCN) —— 装 PyTorch 已就绪

### ● 长期 (大投入, 需团队/资源)

- 高频微观结构因子 (tick 级订单流), 需付费数据, 工作量数月
- 另类数据 (卫星图像、新闻 NLP、信用卡支出、招聘数据)
- 实盘小规模验证 (10 万 → 50 万 → 200 万 → 全仓递进) —— 需券商接口接通

#### 给项目本身的建议

- 当前 IR 0.45 不足以独立实盘——实战通常需要  $IR \geq 1.0$ , 且需要多策略组合分散风险
- 这个项目作为"研究方法论训练"已成功; 作为"实盘策略"还差至少 IR 0.5 的距离
- 真要实盘, 推荐路径: 集成模型 → 加财务因子 → 多策略组合 → 小规模实盘

## 附录 A 项目目录结构

qlib量化研究/ |— PROJECT\_REPORT.pdf ← 本报告 |— PROJECT\_REPORT.md ← markdown 源版 |— CLAUDE.md ← 项目规则与角色设定 | |— configs/ ← qrun YAML 配置 | |— baseline\_lgb\_alpha158.yaml | |— baseline\_lgb\_alpha158\_v2.yaml | |— round3\_best\_lgb\_alpha158.yaml |— factors/ | |— alpha158\_plus.py ← Alpha158 + 估值因子 | |— industry\_neutral.py ← 行业中性化 Processor (R9) |— scripts/ ← 所有工程脚本 (25+) | |— baostock\_collector.py ← OHLCV 采集 | |— valuation\_collector.py ← 估值采集 | |— fetch\_val\_loop.py ← 循环兜底 | |— build\_qlib\_data.py ← CSV → qlib bin | |— collect\_industries.py ← 行业归属采集 | |— round[1-9].py / round8\_5.py ← 各轮回测脚本 | |— figs\_make\_v2.py ← 高质量图表生成 | |— build\_report.py ← 本报告生成器 |— data\_raw/ | |— baostock\_csv/ ← OHLCV (1840 只) | |— baostock\_valuation/ ← 估值 (730 只覆盖) | |— meta/ ← 元数据 JSON / 失败列表 |— results/ |— research\_log.md ← 完整研究日志 |— runs/ ← 每轮 summary.md + CSV/JSON |— mlruns/ ← qrun 的 mlflow artifacts |— figures/ ← 10 张图表 |— figures\_data/ ← 绘图源数据

## 附录 B 工程踩坑记录

1. macOS arm64 lightgbm 缺 libomp → conda-forge 装 `llvm-openmp`
2. numpy 2.x 与 qlib 不兼容 → 锁 `numpy<2`
3. conda 新版需接受 ToS → `conda tos accept --override-channels --channel ...`
4. qlib 默认数据停更 2020-09 → 自建 baostock 管线
5. qlib 回测末尾 IndexError (future calendar) → 测试期末尾留 3 个交易日缓冲
6. baostock 8 worker 并发被限流 (387 失败) → 降到 4 worker + 自动重登
7. 4 worker 仍部分被限 → 单线程兜底 + 1 秒间隔
8. baostock 连接半挂死, retry 接不住 → 设 `socket.setdefaulttimeout(30)`
9. 多 shard 并行被 IP 级限流 → 单连接慢节奏 + 多轮循环
10. Optuna 动态改 `min_child_samples` 与 LightGBM 冲突 → Dataset 设 `feature_pre_filter=False`
11. Python heredoc + lightgbm 多进程冲突 → 写成正式 .py 脚本
12. `n_drop=0` 在 qlib 中实际是每日全换 → 这选项是个坑

## 附录 C 术语词典

| 术语                   | 含义                                     |
|----------------------|----------------------------------------|
| IC / Rank IC         | 因子预测能力（皮尔逊 / 斯皮尔曼相关）                   |
| ICIR / RankICIR      | IC 的稳定性（mean/std），衡量信号质量               |
| 净超额（net excess）      | 策略收益 - 基准收益（含交易成本）                     |
| 信息比率（IR）             | 净超额年化 / 超额波动年化， <b>衡量纯 alpha 质量</b>    |
| 净夏普（net Sharpe）      | 策略净年化收益 / 策略波动， <b>含市场 beta</b>        |
| n_drop               | TopkDropoutStrategy 中每日强制换股数           |
| topk                 | 每日持仓股票数                                |
| 幸存者偏差                | 只统计活下来的股票（赢家），结论虚高                     |
| 含偏 v3 / 去偏 v4        | 当前 500 成分 vs 历史并集 1623 只               |
| Alpha158 / Plus      | 158 量价因子 / 168（+ 10 估值）                |
| LightGBM             | 梯度提升树模型，量化界默认首选                        |
| Optuna               | 贝叶斯超参优化框架                              |
| GBDT                 | Gradient Boosting Decision Tree（梯度提升树） |
| 过拟合                  | 模型在训练集表现好，在新数据失灵                       |
| 多空对冲（market neutral） | 同时做多和做空，对冲市场 beta                      |
| long-only 多头         | 只买不卖，承担市场风险敞口（我们的策略）                   |

## 关于本报告

本报告由 9 轮迭代研究的完整结果整理而成。所有数据、脚本、原始 markdown 报告均存放在项目仓库 [~/qlib](#) 量化研究/，可任意复现。

可视化图表由 `scripts/figs_make_v2.py` 生成（matplotlib + 自定义配色），本 PDF 报告由 `scripts/build_report.py` 生成（HTML + CSS → Playwright Chromium PDF）。

**"好的研究不是找到漂亮的数字，而是排除所有可能让数字漂亮的虚假理由。"**

